

大模型落地浪潮下，嵌入式软硬件工程师的机会地图：从职业升级到独立创业

执行摘要

核心判断：未来几年，嵌入式工程师最大的机会，并不是简单地“学会调用大模型 API”，也不是把自己转成纯算法工程师，而是成为连接“模型世界”与“物理世界”的那一层。

全球 AI 已经从“模型能力竞赛”进入“规模化部署与 ROI 验证”阶段。McKinsey 2025 年调查中，88% 的受访组织已在至少一个业务职能中经常使用 AI，但真正开始企业级规模化部署的只有约三分之一；62% 已经至少开始试验 AI Agent。也就是说，**模型本身越来越容易获得，而把模型变成可靠、低延迟、低成本、可维护、可认证的真实产品，仍然是瓶颈。** 1

这一转变对嵌入式工程师尤其有利，因为 AI 正从云端向手机、PC、汽车、机器人、工业设备、摄像头、智能家居和医疗终端扩散。中国政策甚至把“端侧推理芯片、边缘计算服务器、大模型一体机”直接列入“人工智能+制造”的基础能力，到 2027 年计划推动 3-5 个通用大模型在制造业深度应用、形成 1000 个工业智能体和 500 个典型应用场景。 2

真正稀缺的不是“会 LLM”，而是下面这个交集：

嵌入式 Linux / RTOS + 硬件接口 + GPU/NPU + 模型量化部署 + 实时系统 + 功耗热设计 + 传感器 + 网络通信 + 安全可靠 + 场景工程。

这类人才可以同时吃到三种红利：

路径	主要价值	天花板
就业升级	从传统 BSP/驱动/MCU 开发进入 Edge AI、机器人、智能汽车、端侧模型部署	高
高价值技术服务	为硬件厂、机器人公司、工业客户做模型移植、性能优化、端侧方案集成	很高
产品/创业	把“模型+硬件+场景”做成垂直 AI 设备、模组、SDK 或行业方案	最高但风险最大

从个人战略看，我更推荐一种“**杠铃式路径**”：一边继续保持 C/C++、Linux、驱动、RTOS、硬件调试、网络和实时控制这些难以被大模型替代的底层能力；另一边迅速补齐 PyTorch、量化、ONNX/ExecuTorch/llama.cpp、GPU/NPU、VLM/Agent 等端侧 AI 技能。中间那些单纯“写普通业务代码”的工作反而最容易被压缩。

独立参与这轮浪潮，也不意味着一定要融资做“大模型公司”。更现实的机会往往是：

卖一个设备、一个模组、一个 SDK、一套部署能力、一项行业解决方案，或者把一个优秀开源项目做成事实标准。

Edge Impulse 就是典型案例：它没有训练基础模型，而是做“模型到 MCU/边缘设备”的开发、部署和监控平台，形成超过 17 万开发者的生态，2025 年被 Qualcomm 收购。中国 M5Stack 则通过模块化 ESP32 硬件、软件工具和开发者生态，把“开发板”做成商业平台，2024 年被乐鑫科技收购控股。³

因此，对已有嵌入式经验的人而言，当前值得押注的方向不是“再做一个 ChatGPT”，而是“让 AI 真正进入设备”。

宏观背景与市场窗口

全球正在从训练竞赛转向部署竞赛

IDC 的预测显示，全球企业 AI 解决方案支出在 2025 年约为 **3070 亿美元**，到 2028 年预计达到 **6320 亿美元**，对应 2024-2028 年约 29% CAGR；其中 **生成式 AI** 支出预计从 2025 年约 691 亿美元增长到 2028 年超过 2020 亿美元。需要注意，IDC 不同年份预测的统计口径和基准年份存在调整，所以这些数字更适合看趋势，而不是机械拼成一条绝对精确的时间序列。⁴

IDC 的另一项经济影响模型预计，到 2030 年 AI 对全球经济的直接、间接和诱导影响累计可能达到约 **19.9 万亿美元**，2030 年约相当于全球 GDP 的 3.5%；这是经济影响模型，并不是“AI 市场规模”。⁵

Stanford 2026 AI Index 同样显示资本投入仍在快速上升：2025 年全球企业 AI 投资同比增长超过一倍，私人 AI 投资达到约 3447 亿美元；生成式 AI 是其中增长最快的部分之一。美国私人 AI 投资显著领先中国，但 Stanford 特别提醒，仅比较私人投资会低估中国通过政府引导基金等渠道投入的资本。⁶

更重要的是，产业正在从“有 AI”转向“AI 能否赚钱”。McKinsey 最新调查中，88% 的组织已经使用 AI，但约三分之二还没有实现企业级规模化；只有 39% 的受访者报告 AI 对企业整体 EBIT 已产生任何程度的影响。制造业、软件工程和 IT 是当前最常报告出成本收益的领域之一。⁷

BCG 2026 AI Radar 中，企业预计将 AI 投入从约占收入的 0.8% 提升到约 1.7%；94% 的受访组织表示，即使短期回报不明显，也计划继续投资。⁸

这意味着未来竞争重点逐渐从：

谁有更大的模型

变成：

谁能以更低成本、更低延迟、更高可靠性把模型嵌进真正的业务与设备。

而后者恰好大量依赖嵌入式系统工程。

中国的窗口尤其偏向“端侧+制造+机器人”

中国 AI 产业规模的公开统计存在明显口径差异。援引中国信通院数据的官方信息显示，2024 年中国人工智能核心产业规模已超过 **9000 亿元人民币**，2025 年初步估计超过 **1.2 万亿元**；另一方面，其他官方渠道援引不同统计体系给出的 2024 年规模超过 7000 亿元。因此，不能把不同数字直接比较为同一市场序列。

信通院 2025 年人工智能产业研究已经把基础模型演进、具身智能、算力基础设施、AI 原生应用以及安全治理放在同一产业框架中讨论，反映出的趋势不是“模型单独发展”，而是模型、终端、算力和行业应用共同演进。

政策信号更明确。

2025 年国务院《关于深入实施“人工智能+”行动的意见》提出，到 **2027 年新一代智能终端、智能体等应用普及率超过 70%，到 2030 年超过 90%**；政策同时提出财政、金融、长期资本、政府采购、人才和安全治理等支持措施。

2026 年八部门“人工智能+制造”专项行动进一步提出，到 2027 年：

推动 3-5 个通用大模型在制造业深度应用，推出 1000 个工业智能体、100 个工业高质量数据集、500 个典型应用场景，并支持端侧推理芯片、AI 服务器、边缘计算服务器和大模型一体机。

此外，中国生成式 AI 服务备案数量仍在快速增加。截至 2026 年 4 月 30 日，累计已有 **868 项生成式人工智能服务完成备案**，另有 **530 个应用或功能完成登记**。

机器人尤其值得嵌入式工程师关注。国际机器人联合会数据显示，全球 2024 年新增工业机器人约 **54.2 万台**，运行中的工业机器人存量约 466 万台；中国新增安装约 29.5 万台，占全球约 54%，中国本土机器人厂商在国内市场份额升至 57%。

因此，从中国的产业结构看，我会把未来五年的机会强度排序为：

机器人/具身智能 ≈ 智能汽车 > 工业边缘 AI > AIoT/智能家居 > 新型消费电子 > 医疗端侧 AI。

医疗的单项目价值可能更高，但法规和验证周期显著更长。

为什么“端侧”会长期存在，而不是全部回云端

端侧推理并不是为了取代云模型，而是解决云端天然难以解决的问题：

约束	纯云模式问题	端侧价值
延迟	网络 RTT 和排队不可控	本地推理可获得稳定响应
离线	工厂、汽车、户外机器人可能断网	仍可执行核心功能
隐私	图像、语音、医疗和生产数据外传敏感	数据可尽量留在设备
成本	高频调用会持续产生 token/API/带宽成本	一次性硬件成本可摊销

约束	纯云模式问题	端侧价值
实时控制	云端无法提供硬实时保证	MCU/RTOS 本地闭环
数据量	多路高清视频上传成本高	本地筛选、压缩、理解
产品差异化	云 API 容易被竞争者复制	软硬一体优化可形成壁垒

Raspberry Pi 在介绍搭载 Hailo-10H 的 AI HAT+ 2 时，就明确把离线运行、低延迟、降低云 API 成本和数据安全作为端侧生成式 AI 的价值。 ¹⁴

所以未来更可能出现的是：

云端“大脑” + 边缘“小脑” + MCU“脊髓反射”

而不是单一架构。

这恰好意味着传统嵌入式能力不会消失，而是被 AI 重新放大。

技术栈、硬件平台与工程岗位

嵌入式工程师在 LLM 系统里究竟做什么

一个真正可量产的 AI 设备，工程链条大致是：

传感器 → 驱动/BSP → 数据预处理 → AI/VLM/LLM → Agent/决策 → 实时控制 → 通信 → 云服务 → OTA/监控

模型只在中间占了一层。

嵌入式工程师的新工作内容可以具体拆成：

技术方向	实际工作	核心能力
Edge inference	将 LLM/VLM/ASR 模型部署到 ARM/GPU/NPU	C++、Python、CUDA、runtime
模型压缩	INT8/INT4、weight-only、剪枝、蒸馏	PyTorch、AWQ、SmoothQuant
Kernel/加速	GEMM、attention、FlashAttention、算子融合	CUDA、SIMD、NEON、profiling
SoC/BSP	GPU/NPU 驱动、Device Tree、DMA、IOMMU、PCIe/MIPI	Linux kernel、Yocto、U-Boot
固件/实时	电机、传感器、watchdog、fault handling	C/C++、FreeRTOS/Zephyr

技术方向	实际工作	核心能力
功耗与热	DVFS、idle、thermal throttling、功耗预算	PMIC、thermal、power profiling
Sensor Fusion	Camera/IMU/LiDAR/Radar/audio 时间同步与融合	ROS 2、Kalman、timestamps
Connectivity	CAN/CAN-FD、EtherCAT、Ethernet、Wi-Fi、BLE、5G	网络栈、现场总线
安全	Secure Boot、密钥、加密、OTA、模型保护	TPM/TEE、安全启动
系统可靠性	crash recovery、降级、offline fallback	systemd、watchdog、A/B OTA

其中“模型压缩”并不是纯算法研究人员的专属工作。

例如 AWQ 研究表明，LLM 权重中存在少量对模型质量特别敏感的权重，可以利用硬件友好的低比特量化降低模型内存占用；SmoothQuant 则通过平滑激活值实现 W8A8 的后训练量化。¹⁵

针对真实边缘设备的研究还发现，低比特量化不仅影响内存和速度，也可能显著降低能耗，但具体收益高度依赖模型、芯片、runtime 和 workload，不能把单篇论文中的节能百分比直接当作通用结论。¹⁶

这也是一个重要职业分界：

未来值钱的人不是“知道 INT4 是什么”，而是能解释为什么这个模型在这块 SoC 上 INT4 反而没有预期提速，并把问题定位到内存带宽、kernel、KV cache、runtime 或算子支持的人。

软件栈正在快速成熟

目前值得嵌入式工程师重点关注的部署栈包括：

llama.cpp 的目标就是让 LLM/VLM 能够在广泛硬件上以较少依赖实现本地推理，是理解 GGUF、CPU/GPU 混合卸载、量化和本地模型工程的非常好入口。¹⁷

ExecuTorch 已在 2025 年进入 1.0，并于 2026 年成为 PyTorch Core 的一部分，目标是把 PyTorch 模型部署到手机、嵌入式系统、AR/VR 和其他 edge device。¹⁸

ONNX Runtime 支持 CPU、GPU、NPU 等多类执行后端，并通过 Execution Provider 接入 CUDA、TensorRT、OpenVINO、QNN、CoreML 等硬件栈。¹⁹

MLC-LLM 则强调通过机器学习编译实现跨平台 LLM 部署。²⁰

对 NVIDIA 平台，还应学习 JetPack、CUDA、TensorRT、Nsight、Isaac ROS；对 MCU 则要掌握 TensorFlow Lite Micro、CMSIS-NN、ESP-DL 等。

硬件平台比较

下面价格为 **2026 年 8 月能从官方资料确认的美元标价**；地区、税费、模组与开发板区别会导致实际采购价明显不同。“TOPS”之间也不是完全可比的 benchmark，尤其 INT8 TOPS 与 FP4 sparse TFLOPS 不能横向直接相除。

平台	AI 算力	功耗	官方参考 价格	内存	LLM/VLM 适 合度	最适合
NVIDIA Jetson Orin Nano Super	67 INT8 TOPS	7-25 W	~\$249	8 GB LPDDR5	★★★★☆	学习、原型、小 机器人
NVIDIA Jetson AGX Orin	最高约 275 TOPS	15-60 W	Dev Kit 当 前约 \$3,499	最高 64 GB	★★★★★	工业/机器人高 性能部署
NVIDIA Jetson Thor	2070 FP4 sparse TFLOPS	40-130 W	\$5,499	128 GB	★★★★★	高端具身智能/ VLA
Raspberry Pi 5 + AI HAT+ 2	40 INT4 TOPS	NPU 典 型约数 W 级	HAT \$200 + Pi	HAT 8 GB	★★★★☆	低成本 GenAI 产品原型
Google Coral Edge TPU	4 TOPS	约 2 W NPU	未指定/存 量市场	外部主机	★☆☆☆☆	TinyML/CV，不 适合现代 LLM
Intel Movidius NCS2	官方当前未 给统一 TOPS	USB 功 耗级	已停产	Myriad X 内部	★☆☆☆☆	维护旧 OpenVINO 项 目
Orange Pi RV2 / RISC-V	2 TOPS	未指定	未指定	2/4/8 GB	★★☆☆☆	RISC-V、低成本 边缘研究

Jetson Orin Nano Super 官方规格为 67 INT8 TOPS、8 GB LPDDR5、102 GB/s 内存带宽和 7-25 W 功耗，并明确定位 LLM、VLM、机器人等生成式 AI 工作负载。 ²¹

Jetson Thor 则提升到 2070 FP4 sparse TFLOPS、40-130 W，目前 NVIDIA 官方开发套件标价 5499 美元，其定位已经非常明显地指向下一代机器人/physical AI。 ²²

Raspberry Pi AI HAT+ 2 搭载 Hailo-10H，提供 40 INT4 TOPS 和独立 8 GB RAM，当前官方价格 200 美元，并明确支持本地 LLM/VLM。 ¹⁴

Google Coral 的早期 Edge TPU 约为 4 TOPS、2 TOPS/W，设计时代主要围绕 TensorFlow Lite Edge AI；因此它仍适合 CV/TinyML 教学或既有系统，但并不是今天端侧 LLM 的理想起点。 ²³

Intel Movidius Neural Compute Stick 2 已进入停产状态，因此更适合维护遗留项目，而不是作为新项目长期技术路线。 ²⁴

Orange Pi RV2 搭载 RISC-V Ky X1，公开规格提供约 2 TOPS NPU 与最高 8 GB LPDDR4X，其意义主要在于研究 **RISC-V + AI accelerator + Linux** 的未来国产/开放架构，而不是跑大型 LLM。 25

一个非常重要的系统架构原则

不要试图让 LLM 负责所有事情。

机器人、电机、汽车或工业控制里，更成熟的设计通常应当把：

硬实时、安全闭环、watchdog、急停


留在 MCU/RTOS ；

而把：

视觉、语言理解、规划、语义决策

放在 Linux SoC/GPU/NPU。

例如：



LLM 即使 hallucinate，底层 safety controller 也不应该允许它直接输出一个未经约束的 PWM、电机电流或制动指令。

这会成为具身智能时代非常重要的嵌入式架构能力。

就业市场与能力门槛

职位名称正在发生变化

未来不一定会出现统一的“LLM 嵌入式工程师”名称，目前招聘市场更多表现为以下混合岗位：

岗位	英文常见名称	技能关键词
端侧 AI 工程师	Edge AI Engineer	ONNX/TensorRT/NPU/C++
模型部署工程师	Model Deployment Engineer	quantization/runtime/CUDA
AI 推理优化工程师	AI Inference Engineer	kernel/GPU/profiling
Embedded ML Engineer	Embedded ML Engineer	MCU/SoC/TinyML
机器人系统工程师	Robotics Systems Engineer	ROS 2/C++/sensor
具身智能部署工程师	Embodied AI Deployment Engineer	VLM/VLA/Jetson
BSP/AI Platform Engineer	Embedded Platform Engineer	Linux/BSP/driver
AI Accelerator Engineer	NPU/ASIC Engineer	RTL/compiler/kernel
Automotive AI Engineer	Automotive Embedded AI	AUTOSAR/CAN/SoC
Firmware AI Engineer	AI Firmware Engineer	RTOS/DSP/NPU firmware

McKinsey 2025 调查中，在企业近期的 AI 招聘岗位里，软件工程师和数据工程师仍是最常被报告的需求类别之一。²⁶

美国 BLS 也预计软件开发人员就业在 2024–2034 年增长约 **16%**，并明确把 AI、IoT、机器人和自动化应用列为推动软件开发需求的因素；计算机硬件工程师预计同期增长约 **7%**。²⁷

这并不能直接证明“嵌入式 LLM 岗位会增长 X%”，因为目前官方职业统计中并没有这么细的分类，但它说明 **AI+IoT+机器人+物理产品的软件需求并没有随着 AI 编程工具出现而消失。**

中国薪资

目前没有权威全国统计把“端侧 LLM/Embedded AI Engineer”单列成职业，所以只能使用公开招聘作为样本，不能理解成全国薪资均值。

2025–2026 年公开职位样本中：

类型	公开招聘样本
AI 嵌入式软件	约 ¥20k–35k/月 × 14
端侧大模型开发	约 ¥20k–40k/月 × 14

类型	公开招聘样本
机器人 Embedded Linux	约 ¥25k-45k/月
具身模型部署	约 ¥30k-50k/月 × 15
嵌入式机器学习	约 ¥30k-50k/月 × 13-15
高级大模型算法	部分岗位约 ¥40k-65k/月 × 15

例如公开招聘样本中，DJI 嵌入式机器学习相关职位出现约 30-45K×15、30-50K×13 的区间；上海部分具身智能模型部署岗位出现 30-50K×15，具身嵌入式岗位约 20-40K；端侧大模型开发职位也出现 20-40K×14 的样本。 ²⁸

这些数字受城市、年限、奖金、股票、公司阶段影响非常大，只能用来判断 **技术交叉岗位的价格中枢通常高于普通 MCU/BSP 维护岗**，不能当成个人报价标准。

少量公开兼职职位甚至已经直接出现“Embedded AI / AIoT / Edge AI / LLM”形式的按小时项目，但公开样本极少，不足以形成可靠市场价格统计。 ²⁹

美国及全球参考

美国 BLS 2024 年工资数据显示：

软件开发工程师中位年薪约 133,080 美元；计算机硬件工程师约 155,020 美元。 ²⁷

真正处于 AI+embedded 前沿的企业岗位明显高于这一平均水平。例如 NVIDIA 公开的 TensorRT Edge-LLM、汽车/机器人 Embedded Platform 等高级工程职位，部分基本薪酬区间约为 **184k-287.5k 美元/年**，更高职级可能进一步达到 300k 美元以上；这些属于顶级美国科技公司的特殊岗位，不能视为行业中位数。 ³⁰

中国以外其他国家目前没有足够统一、同口径的“Embedded LLM Engineer”薪酬统计，**未指定**。

到底应该会哪些技能

我会把技能分成四层：

第一层：不能丢的嵌入式硬实力

C/C++、Linux、RTOS、ARM、Device Tree、U-Boot、驱动、SPI/I²C/UART/CAN、网络、GDB、perf、CMake、交叉编译、Git。

第二层：AI deployment

Python、PyTorch、Transformers、ONNX、llama.cpp、ExecuTorch、TensorRT、量化、GGUF、LoRA、KV cache、tokenizer、profiling。

第三层：Edge/robotics

CUDA、ROS 2、OpenCV、GStreamer、camera pipeline、sensor fusion、Docker、MQTT、CAN-FD、EtherCAT。

第四层：product engineering

Secure Boot、OTA、A/B partition、SBOM、CI/CD、日志、telemetry、功耗、thermal、EMC、reliability。

最稀缺的是能同时跨过第二层和第一层的人。

证书的重要性低于作品，但行业标准很重要

目前不存在业界统一要求的“LLM 嵌入式工程师认证”。NVIDIA 等厂商提供培训和认证，但对大多数开发岗来说，能够展示真实硬件 benchmark、代码和完整系统作品通常比课程证书更有说服力。NVIDIA 自身也提供针对加速计算与 AI 的培训/认证体系。 ²²

真正进入汽车、工业、医疗后，行业规范的重要性会快速增加。例如汽车领域 ISO 26262 覆盖安全相关 E/E 系统的功能安全生命周期；工业控制安全对应 IEC 62443；医疗设备软件生命周期则涉及 IEC 62304。 ³¹

因此，更好的策略并不是“收集 AI 证书”，而是：

选择一个行业，把它的 safety/security/regulatory language 学会。

这往往能形成比某个框架证书更长久的职业壁垒。

产品、商业模式与独立路径

真正适合个人和小团队的产品机会

最容易犯的错误是：

“现在大模型火，我做一个 AI 硬件。”

这是产品定义，而不是商业需求。

更好的问题应该是：

“哪个现实世界流程，每天重复 100 次，而且目前依赖一个人在现场看、听、判断或查询？”

这才是 edge AI 的机会来源。

我会优先看以下领域：

垂直行业	可以做什么	购买者	商业模式	收入潜力*	小团队可行性
工业	AI 视觉质检、故障诊断盒、维修 Copilot	工厂/集成商	硬件+软件年费	★★★★★	★★★★★
机器人	VLM 控制盒、语音交互、导航/操作模块	机器人 OEM	模组+SDK+授权	★★★★★	★★★★☆
汽车	座舱 AI、DMS、离线语音、诊断	Tier1/OEM	NRE+license	★★★★★	★★☆☆☆
AIoT	本地智能网关、能源管理、安防	企业/家庭	硬件+订阅	★★★★☆	★★★★★
医疗设备	离线语音记录、设备助手、监测	医疗厂商	OEM/license	★★★★★	★★☆☆☆
消费电子	AI 玩具、桌面机器人、翻译器	消费者	硬件+服务	★★★★☆	★★★★☆
农业	病虫害检测、巡检、自动控制	农场/集成商	设备+SaaS	★★★★☆	★★★★☆

*“收入潜力”为本文基于客单价、部署数量、复购/软件收入和进入壁垒做出的相对判断，并非市场规模预测。

工业和机器人尤其值得注意，因为机器人安装量和制造业 AI 政策都已经给出了明确的产业化信号。 32

六类适合独立工程师的商业模式

项目型咨询

最容易开始。

例如：

“把客户的 Qwen/MiniCPM/Llama 模型移植到 RK3588/Jetson。”

收入来自 NRE、按天或按项目咨询。

缺点是没有复利。

产品化咨询

比纯外包更好。

例如针对工业摄像头做：

Jetson/RK3588 + VLM + OPC-UA/Modbus + Web UI + OTA

做成一套 reusable stack。

同一套软件可以卖给十家客户。

SDK / IP licensing

例如开发：

- INT4 inference backend
- CAN+LLM diagnostic SDK
- offline voice SDK
- industrial VLM runtime
- NPU abstraction layer

按设备 license、年度 license 或 OEM 授权收费。

这是技术型工程师最值得追求的模式之一。

硬件产品

例如：

- Edge AI Box
- AI Camera
- AI Gateway
- Robot Brain Module
- Voice AI Module

收入：

硬件售价 - BOM - 制造 - 渠道成本

关键不是“硬件利润”，而是通过硬件建立安装基数。

Hardware-as-a-Service

例如工业巡检盒：

¥799/月/节点

客户不买设备，你拥有设备，持续收订阅。

这可以把一次性项目收入转换为 ARR。

开源 + 商业服务

模式类似：

Open-source runtime
↓
Developer adoption
↓
Enterprise support
↓
OEM/custom hardware
↓
Cloud/device management

这是非常适合嵌入式 AI 的长期模式，因为硬件天然碎片化，企业往往愿意为“稳定支持”付费。

单位经济不能只看“模型成本”

一个简单的工业 AI Box 可以这样算账。

以下数字是**示范模型**，不是市场报价：

假设：

硬件 BOM	¥4,000
制造/物流/安装	¥1,500
一次性售价	¥12,000

那么一次性贡献毛利：

$12,000 - 4,000 - 1,500$
 $= ¥6,500$

再加：

设备管理/模型更新
¥2,400 / 年

假定年服务可变成本 ¥600，则：

服务年贡献 = ¥1,800

部署 100 台：

$$\begin{aligned} \text{首年贡献} &\approx \\ 100 \times (6,500 + 1,800) \\ &= ¥830,000 \end{aligned}$$

这还没有扣销售、研发、人力和公司运营费用，但已经显示了一个关键问题：

边缘 AI 生意真正好看的地方，往往不是硬件本身，而是“硬件安装基数 × 软件/维护/模型收入”。

因此，不要做：

“卖一块板子。”

而要做：

“卖一块板子 + 一项持续能力。”

独立参与浪潮的几个真实案例

llama.cpp：个人/开源项目成为基础设施

llama.cpp 的核心目标是让 LLM/VLM 能够以较少依赖运行于广泛硬件平台，本质上直接解决“LLM 如何从数据中心走向普通设备”的问题。¹⁷

它说明独立工程师不一定需要创建模型；把现有模型运行得更快、更容易、更跨平台，本身就可能产生巨大的生态价值。

Edge Impulse：从 Edge AI 工具链做到战略收购

Edge Impulse 提供从数据、模型开发到 MCU/边缘设备部署和监控的工具链，Qualcomm 在 2025 年宣布收购时称该平台已服务超过 **17 万开发者**，应用覆盖资产监控、制造、异常检测、预测性维护、视觉、音频等。³³

最值得学习的是：

它卖的不是一个模型，而是“模型到设备的最后一公里”。

M5Stack：中国开发者硬件生态的产品化案例

M5Stack 从模块化 ESP32 硬件发展出硬件、UIFlow、AI/IoT 软件和定制服务体系。公司官方披露其产品已覆盖 110 多个国家、累计销售超过 300 万件，并形成超过 18 万人的开发者/创客社区；这些属于公司自报数据。2024 年乐鑫科技收购其多数股权。³⁴

其经验不是“做一块爆款开发板”，而是：

模块 → 开发者 → 软件 → 应用 → SKU → OEM。

2026 年 M5Stack 还在把 StackFlow 等能力扩展到 embedded AI。 35

Seeed Studio：从开发板升级到 Edge AI 基础设施

Seeed 的 reComputer 产品线把 Jetson SoM 与 carrier board、散热、存储、机箱和软件支持组合成 edge AI 平台，并进一步通过 SenseCraft/reComputer AI Lab 提供 CV、LLM、VLM 模型和部署工具。 36

其商业价值来自：

hardware + integration + manufacturing + ODM + fulfillment + software ecosystem。

Seeed 官方也明确把自身定位为帮助客户从原型走向量产的集成、ODM 和制造伙伴。 37

这非常值得个人工程师学习——越靠近“客户从 Demo 到量产”的痛点，越容易收费。

中国端侧模型正在主动向硬件靠拢

面壁智能 MiniCPM 系列明确以端侧模型为重要方向。其 MiniCPM 4 系列包含 8B 和 0.5B 等规模，并通过量化、稀疏等方法针对端侧部署优化；2026 年还公布了面向端侧智能开发的“松果派”硬件计划。 38

这个趋势很关键：

以前：

芯片厂 → 工程师负责适配模型。

以后越来越可能：

模型设计 ↔ compiler/runtime ↔ chip ↔ hardware ↔ application

从一开始就协同设计。

懂模型又懂 SoC 的工程师，价值会因此上升。

技能路线与十二个月行动计划

学习路线不要从“学 Transformer 数学”开始

对于已经是嵌入式工程师的人，我建议：

先学部署，再补模型原理。

原因很简单：你的差异化不是和算法博士竞争训练模型，而是把模型放进物理系统。

短期：建立 Edge LLM 基线

目标时间：约两个月。

重点：

Python
PyTorch
Transformers
llama.cpp
GGUF
INT8 / INT4
ONNX
Docker
Jetson

需要真正理解：

- prefill 与 decode
- tokens/s
- TTFT
- KV cache
- context length
- model memory
- quantization
- CPU/GPU offload
- memory bandwidth
- latency vs throughput

Portfolio 项目：

Jetson Orin Nano 本地 LLM benchmark

至少测：

模型大小
量化等级
RAM
启动时间
TTFT
tokens/s
CPU/GPU usage
功耗
温度

不要只录一段“模型跑起来了”的视频。

Benchmark 本身就是作品。

中期：从模型部署进入系统工程

目标时间：三到六个月。

学习：

```
TensorRT
ONNX Runtime
ExecuTorch
CUDA basics
Nsight
GStreamer
OpenCV
ROS 2
MQTT
CAN
Modbus
```

做一个真正的 multimodal project：

Camera → VLM → LLM → structured command → MCU

例如：

```
摄像头看到设备仪表
↓
VLM 读取读数/状态
↓
LLM 分析异常
↓
JSON command
↓
ESP32
↓
蜂鸣器 / relay / motor
```

最重要的不是模型精度，而是实现：

- watchdog
- timeout

- malformed output handling
- network disconnect
- sensor disconnect
- model crash recovery
- OTA
- logging

这才会让作品从“AI Demo”变成“嵌入式系统”。

长期：做软硬件协同

六到十二个月时，应开始研究：

```
BSP
Device Tree
NPU runtime
DMA
Zero-copy
Quantization-aware deployment
Kernel profiling
Power/thermal
Secure Boot
OTA
```

然后选择一个垂直领域：

机器人：

ROS 2、Isaac ROS、camera/IMU、motor control、VLM/VLA。

工业：

Modbus、OPC-UA、EtherCAT、IEC 62443、工业相机。

汽车：

CAN-FD、AUTOSAR 基础、ISO 26262、车载 Linux/QNX。

消费电子：

ESP32、BLE、Wi-Fi、Matter、audio、低功耗。

医疗：

IEC 62304、风险管理、数据安全、可验证性。

39

最推荐的硬件组合

预算有限：

ESP32-S3
+
Raspberry Pi 5 / AI HAT+2

ESP32-S3 自带用于 NN/DSP 工作负载的向量指令，并提供 Wi-Fi/BLE、Secure Boot 和 Flash Encryption，非常适合学习“MCU + AI SoC”双层架构。 40

预算中等：

ESP32-S3
+
Jetson Orin Nano Super

这是我最推荐的组合。

原因是可以同时学习：

RTOS
Linux
CUDA
LLM
VLM
sensor
robotics
network

而且 Orin Nano Super 已经能够真实运行多种 LLM/VLM。 21

Portfolio 应该长什么样

不要做十个 ChatGPT UI。

做三到四个真正系统级项目更有价值。

项目一：Offline multimodal industrial copilot

Jetson
Camera

```
Mic
VLM
LLM
local RAG
Modbus
Web UI
```

核心指标：

TTFT、tokens/s、功耗、断网能力。

项目二：LLM + RTOS robot

```
Jetson
|
ROS 2
|
ESP32
|
Motor + IMU
```

LLM 负责意图，MCU 负责硬实时。

项目三：Quantization Benchmark Suite

比较：

```
FP16
INT8
INT4
```

记录：

```
quality
latency
memory
energy/token
thermal
```

AWQ、SmoothQuant 等论文可以成为实验基线。

15

项目四：Secure Edge AI Appliance


加入：

Secure Boot
signed OTA
A/B partition
encrypted model
watchdog
telemetry

这—个项目在面试或拿 B2B 客户时，很可能比再实现—次 RAG 更有区分度。

十二个月执行计划

假定从 2026 年 8 月开始：



对应的 milestone 应该非常明确：

时间点	必须产出
两个月	一个公开 Edge LLM benchmark repo
四个月	一个真实 Jetson VLM/LLM 项目
六个月	一个 MCU + AI SoC 完整设备
八个月	选定一个垂直行业
九个月	与至少 5-10 个真实潜在用户交流
十个月	一个可付费 MVP
十二个月	至少完成一次销售、付费咨询、OEM 试用或开源社区验证

这里最重要的 milestone 不是：

“学完 CUDA”。

而是：

有人愿意因为你做出来的东西付钱、采用或贡献代码。

风险、约束与最终判断

最大技术风险不是模型，而是系统不可靠

典型失败路径包括：

```
模型升级 → 算子不支持
Driver升级 → runtime崩
温度上升 → throttling
context增长 → OOM
sensor丢帧 → VLM误判
LLM输出格式错误 → actuator异常
断网 → Agent失效
OTA失败 → device brick
```

因此应该从第一天建立：

```
fallback
watchdog
health monitoring
structured output
resource limit
A/B update
offline mode
```

这也是传统嵌入式工程师相对纯 AI 工程师最大的优势之一。

合规会越来越“进入固件”

中国已经要求符合适用范围的 AI 生成合成内容服务对文本、图片、音频、视频和虚拟场景等内容加入显式和隐式标识；相关办法自 2025 年起进入实施体系。⁴¹

生成式 AI 对公众提供服务时，还可能涉及生成式 AI 服务管理、安全评估和算法备案等要求；实际是否适用于某个离线设备、企业内部设备或公网产品，需要根据产品形态逐项判断。⁴²

如果产品进入欧盟，EU AI Act 已于 2026 年 8 月 2 日进入主要适用阶段；部分嵌入受监管产品的高风险 AI 规则有更长过渡期，到 2027-2028 年分阶段适用。⁴³

这意味着未来 embedded AI 的一项新能力将是：

policy → system requirement → firmware/software implementation

例如：

```
AI标识
audit log
model version
consent
data retention
access control
```

最终都会变成代码。

供应链不能忽略

先进 AI 芯片已经是贸易政策和出口管制的重要对象。例如美国 BIS 在 2025–2026 年持续调整针对先进计算芯片、相关出口和中国市场的许可政策。 ⁴⁴

因此创业时不应该让产品：

只能跑在一颗无法替代的芯片上。

更合理的是做 runtime abstraction：

```
Application
|
AI Runtime API
|
├── Jetson
├── RK3588
└── Qualcomm ...
```

即使第一版只支持 Jetson，也应从架构上保留迁移能力。

医疗、汽车和高工业的高利润来自高门槛

汽车需要面对 ISO 26262 等功能安全框架；医疗软件生命周期涉及 IEC 62304；工业控制网络和产品安全则越来越受到 IEC 62443 系列影响。 ⁴⁵

这看起来是障碍，但其实也是护城河。

普通 AI App：

一个月可能出现几十个竞争者。

通过汽车、工业或医疗验证的嵌入式 AI 方案：

很难被一个周末复制。

所以职业生涯越往后，我反而建议选择一个“有监管、有硬件、有现场、有实时性”的行业。

AI 本身也会降低嵌入式开发门槛

必须承认，大模型也会逐渐自动生成：

```
driver skeleton
C/C++
unit test
device tree
scripts
documentation
basic PCB
```

所以只靠“会写 C”的价值会下降。

真正不容易被替代的是：

知道哪段 AI 生成的 C 会导致 race condition。

知道为什么 DMA buffer 必须 cache coherent。

知道 motor control 为什么不能等待 LLM。

知道 GPU OOM 后系统应该如何降级。

知道硬件在 70°C 与 25°C 的行为为什么不同。

知道客户工厂现场的 Ethernet、EMI、电源和网络环境为什么总会打败 Demo。

这是 embodied AI 时代工程师真正的护城河。

最终机会地图

如果把“机会大小”和“个人可进入性”放到同一个矩阵里，我的判断是：

方向	市场机会	技术壁垒	资本要求	个人/小团队推荐度
Edge AI 部署/优化	★★★★★	★★★★☆	★☆☆☆☆	★★★★★
AI+机器人	★★★★★	★★★★★	★★★★☆	★★★★★
工业 AI Box	★★★★★	★★★★☆	★★☆☆☆	★★★★★
AIoT 模组/SDK	★★★★☆	★★★★☆	★★☆☆☆	★★★★★

方向	市场机会	技术壁垒	资本要求	个人/小团队推荐度
开源 runtime/tool	★★★★★	★★★★★	★☆☆☆☆	★★★★★
AI 玩具/消费设备	★★★★☆	★★★★☆	★★★★☆	★★★★☆
汽车 Tier1 方案	★★★★★	★★★★★	★★★★☆	★★★★☆
医疗 AI 设备	★★★★☆	★★★★★	★★★★☆	★★☆☆☆
自研 AI 芯片	★★★★★	★★★★★	★★★★★	★☆☆☆☆
自研基础大模型	★★★★★	★★★★★	★★★★★	★☆☆☆☆

因此，对于一个已经具有嵌入式软硬件背景的工程师，未来一到三年我认为最优解不是：

“转行 AI。”

而应该是：

“把自己升级成 AI 系统工程师。”

传统嵌入式时代，你解决的是：

如何让软件可靠地控制硬件。

未来的 embedded AI / Physical AI 时代，你解决的是：

如何让不完全可靠、资源消耗巨大的概率模型，在功耗、实时性、安全、成本和物理世界约束下，可靠地控制一台真正的机器。

这件事情比调用 API 难得多，也因此更有价值。

而从独立参与的角度，最值得寻找的也不是下一个“大模型”，而是大模型基础设施成熟之后涌现出的无数“最后一公里”：

模型怎么压到 4 bit，
怎么跑进一块 10 W 的板子，
怎么接摄像头和麦克风，
怎么连 PLC 和电机，
怎么断网还能工作，
怎么控制延迟和温度，
怎么安全 OTA，
怎么量产一万台，
怎么让客户三年之后仍然敢升级模型。

这整个“最后一公里”，恰恰就是嵌入式软硬件工程师最大的下一轮浪潮。

1 7 26 The State of AI: Global Survey 2025 | McKinsey

<https://www.mckinsey.com/capabilities/quantumblack/our-insights/the-state-of-ai>

2 工业和信息化部等八部门关于印发《“人工智能+制造”专项行动实施意见》的通知-国家数据局

https://www.nda.gov.cn/sjj/zwgk/zcfb/0112/20260107214358696030895_pc.html

3 33 Qualcomm to Bolster AI and IoT Capabilities with Edge ...

https://www.qualcomm.com/news/releases/2025/03/qualcomm-to-bolster-ai-and-iot-capabilities-with-edge-impulse-ac?utm_source=chatgpt.com

4 info.idc.com

https://info.idc.com/rs/081-ATC-910/images/US-IDC-FutureScape-2025-GenAI_ebook.pdf

5 info.idc.com

<https://info.idc.com/rs/081-ATC-910/images/IDC-Mapping-Growth-Opportunities-with-AI-AP.pdf>

6 The 2026 AI Index Report | Stanford HAI

https://hai.stanford.edu/ai-index/2026-ai-index-report?utm_source=chatgpt.com

8 As AI Investments Surge, CEOs Take the Lead

https://www.bcg.com/publications/2026/as-ai-investments-surge-ceos-take-the-lead?utm_source=chatgpt.com

9 今年人工智能核心产业规模有望超万亿元 - 服务贸易 - 商务部

https://tradeinservices.mofcom.gov.cn/article/news/gnxw/202512/180609.html?utm_source=chatgpt.com

10 人工智能产业发展研究报告（2025年） - 科研能力

https://www.caict.ac.cn/kxyj/qwfb/bps/202602/t20260202_712679.htm?utm_source=chatgpt.com

11 国务院关于深入实施“人工智能+”行动的意见

https://www.mee.gov.cn/zcwj/gwywj/202508/t20250827_1126207.shtml

12 关于发布生成式人工智能服务已备案信息的公告（2026年3月 ...

https://www.cac.gov.cn/2026-05/13/c_1780413225190669.htm?utm_source=chatgpt.com

13 32 World Robotics 2025 report – INDUSTRIAL ROBOTS

https://ifr.org/ifr-press-releases/news/global-robot-demand-in-factories-doubles-over-10-years?utm_source=chatgpt.com

14 Buy a Raspberry Pi AI HAT+ 2 – Raspberry Pi

<https://www.raspberrypi.com/products/ai-hat-plus-2/>

15 AWQ: Activation-aware Weight Quantization for LLM ...

https://arxiv.org/abs/2306.00978?utm_source=chatgpt.com

16 Evaluating Quantized LLMs for Energy Efficiency, Output ...

https://arxiv.org/html/2504.03360v1?utm_source=chatgpt.com

17 ggml-org/llama.cpp at practical-engineer.ai

https://github.com/ggerganov/llama.cpp?ref=practical-engineer.ai&utm_source=chatgpt.com

18 Introducing ExecuTorch 1.0: Powering the next generation of edge AI

https://pytorch.org/blog/introducing-executorch-1-0/?utm_source=chatgpt.com

19 ONNX Runtime | Home

https://onnxruntime.ai/?utm_source=chatgpt.com

20 **mlc-ai/mlc-llm: Universal LLM Deployment Engine with ML ...**

https://github.com/mlc-ai/mlc-llm?utm_source=chatgpt.com

21 **Jetson Orin Nano Super Developer Kit | NVIDIA**

<https://www.nvidia.com/en-gb/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/>

22 **Jetson Thor Developer Kit | NVIDIA**

<https://marketplace.nvidia.com/en-us/enterprise/robotics-edge/jetson-thor-developer-kit/>

23 **Edge TPU performance benchmarks | Coral - Google**

https://www.coral.withgoogle.com/docs/edgetpu/benchmarks/?utm_source=chatgpt.com

24 **Intel® Neural Compute Stick 2 - Product Specifications**

https://www.intel.com/content/www/us/en/products/sku/140109/intel-neural-compute-stick-2/specifications.html?utm_source=chatgpt.com

25 **OrangePi RV2**

https://www.orangepi.org/html/hardWare/computerAndMicrocontrollers/details/Orange-Pi-RV2.html?utm_source=chatgpt.com

27 **Software Developers, Quality Assurance Analysts, and Testers : Occupational Outlook Handbook: : U.S. Bureau of Labor Statistics**

<https://www.bls.gov/ooh/computer-and-information-technology/software-developers.htm>

28 **机器学习嵌入式招聘信息**

https://www.zhipin.com/zhaopin/c01d0d66741e83341nj_2Ni4Fw~~/?utm_source=chatgpt.com

29 **上海嵌入式ai工程师招聘信息**

https://www.zhipin.com/zhaopin/ad2e411e7a05cded0nd-0ti-EA~~/?utm_source=chatgpt.com

30 **Senior Infrastructure Software Engineer, TensorRT Edge-LLM**

https://nvidia.wd5.myworkdayjobs.com/en-US/NVIDIAExternalCareerSite/job/Senior-Infrastructure-Software-Engineer--TensorRT-Edge-LLM_JR2022855?utm_source=chatgpt.com

31 **Road vehicles — Functional safety - ISO 26262-2:2018**

https://www.iso.org/standard/68384.html?utm_source=chatgpt.com

34 **About M5Stack | Modular IoT Development Platform**

https://m5stack.com/about-us?utm_source=chatgpt.com

35 **m5-docs - M5Stack**

https://docs.m5stack.com/?utm_source=chatgpt.com

36 **What Is reComputer Jetson | reComputer AI Lab - SenseCraft**

https://sensecraft.seeed.cc/ai-lab/en/tutorials/j/recomputer-jetson-platform-overview/what-is-recomputer-jetson?utm_source=chatgpt.com

37 **Edge AI Solutions powered by NVIDIA Jetson platform**

https://www.seeedstudio.com/blog/edge-ai-solutions-powered-by-nvidia-jetson-platform/?srsltid=AfmBOoouwVVGH09cR01WC6Ev7qJs9NMvdAUv3FA435-4ufKL1Wv6bP4i&utm_source=chatgpt.com

38 **面壁智能**

https://modelbest.cn/?utm_source=chatgpt.com

39 **IEC 62304:2006+AMD1:2015 CSV**

https://webstore.iec.ch/en/publication/22794?utm_source=chatgpt.com

40 ESP32-S3 Wi-Fi & BLE 5 SoC

https://www.espressif.com/en/products/socs/esp32-s3?utm_source=chatgpt.com

41 关于印发《人工智能生成合成内容标识办法》的通知_中央网络安全和信息化委员会办公室

https://www.cac.gov.cn/2025-03/14/c_1743654684782215.htm

42 生成式人工智能服务管理暂行办法

https://www.cac.gov.cn/2023-07/13/c_1690898327029107.htm?utm_source=chatgpt.com

43 AI Act | Shaping Europe's digital future

<https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>

44 reject the Biden Administration's AI Diffusion Rule

https://www.bis.gov/press-release/department-commerce-announces-rescission-biden-era-artificial-intelligence-diffusion-rule-strengthens?utm_source=chatgpt.com

45 ISO 26262 road vehicles functional safety

https://www.iso.org/publication/PUB200262.html?utm_source=chatgpt.com